

# Tema HMM, Programare și modelare probabilistică

Adia-Ioana Romanescu (3A3)

November 5, 2024

## Enunț exercițiul 1

Pe baza definiției unui model Markov ascuns, demonstrați formula recurenței pentru variabila forward de la pagina 23 a cursului 4.

## Demonstrație:

Formula pe care dorim să o demonstrăm este:

$$\alpha_t(j) = \left[ \sum_{i=1}^n \alpha_{t-1}(i) \cdot a_{ij} \right] b_j(o_t)$$

unde:

- $\alpha_t(j) = P(o_1, o_2, \dots, o_t, S_t = q_j | \lambda)$ , adică probabilitatea de a observa secvența  $o_1, o_2, \dots, o_t$  și de a fi în starea  $q_j$  la momentul  $t$ ,
- $a_{ij} = P(S_t = q_j | S_{t-1} = q_i)$  reprezintă probabilitatea de tranziție între stările  $q_i$  și  $q_j$ ,
- $b_j(o_t) = P(o_t | S_t = q_j)$  este probabilitatea de observare a simbolului  $o_t$  în starea  $q_j$ .

Vom demonstra folosind metoda inducției matematice.

## Pasul de bază: Verificăm formula pentru $t = 0$

Pentru  $t = 1$ , formula forward  $\alpha_0(j)$  ar trebui să reprezinte probabilitatea ca secvența observată să conțină doar observația inițială  $o_1$  și să fie în starea  $q_j$  la timpul  $t = 1$ . Conform definiției, avem:

$$\alpha_1(j) = P(o_1, S_1 = q_j | \lambda) = P(S_1 = q_j | \lambda) \cdot P(o_1 | S_1 = q_j)$$

Întrucât probabilitatea inițială a stării  $q_j$  este dată de  $\pi_j = P(S_1 = q_j)$  și probabilitatea observației  $o_1$  în starea  $q_j$  este  $b_j(o_1)$ , rezultă că:

$$\alpha_1(j) = \pi_j \cdot b_j(o_1)$$

Aceasta este formula corectă pentru  $t = 0$ , deci pasul de bază este verificat.

## Pasul inductiv:

Presupunem că formula este valabilă pentru  $t - 1$  și vom demonstra că are loc și pentru timpul  $t$ . Cunoscând că formula are loc pentru pasul  $t - 1$ , adică:

$$\alpha_{t-1}(i) = \left[ \sum_{k=1}^n \alpha_{t-2}(k) \cdot a_{ki} \right] b_i(o_{t-1})$$

Ar trebui să rezulte că această relație este valabilă și pentru timpul  $t$ , adică:

$$\alpha_t(j) = \left[ \sum_{i=1}^n \alpha_{t-1}(i) \cdot a_{ij} \right] b_j(o_t)$$

## Demonstrăm formula pentru timpul $t$

Pentru a calcula  $\alpha_t(j)$ , vom folosi definiția probabilităților condiționate și structura de tranziție a modelului Markov ascuns. Astfel,  $\alpha_t(j)$  poate fi descompusă ca suma probabilităților de a ajunge în  $q_j$  la momentul  $t$  din fiecare stare  $q_i$  la momentul  $t-1$ , urmată de observarea lui  $o_t$ :

$$\alpha_t(j) = P(o_1, o_2, \dots, o_t, S_t = q_j | \lambda)$$

Aplicăm regula sumei pentru toate stările posibile  $q_i$  la timpul  $t-1$ :

$$\alpha_t(j) = \sum_{i=1}^n P(o_1, o_2, \dots, o_t, S_{t-1} = q_i, S_t = q_j | \lambda)$$

Folosind independența condițională a HMM, obținem:

$$\alpha_t(j) = \sum_{i=1}^n P(o_1, o_2, \dots, o_{t-1}, S_{t-1} = q_i | \lambda) \cdot P(S_t = q_j | S_{t-1} = q_i) \cdot P(o_t | S_t = q_j)$$

Observăm că  $P(o_1, o_2, \dots, o_{t-1}, S_{t-1} = q_i | \lambda)$  este tocmai  $\alpha_{t-1}(i)$ . În plus,  $P(S_t = q_j | S_{t-1} = q_i) = a_{ij}$  și  $P(o_t | S_t = q_j) = b_j(o_t)$ .

Astfel, formula devine:

$$\alpha_t(j) = \sum_{i=1}^n \alpha_{t-1}(i) \cdot a_{ij} \cdot b_j(o_t)$$

sau, echivalent:

$$\alpha_t(j) = \left[ \sum_{i=1}^n \alpha_{t-1}(i) \cdot a_{ij} \right] b_j(o_t)$$

## Concluzie

Am demonstrat formula de recurență pentru variabila *forward* folosind inducția matematică, arătând că relația este valabilă pentru  $t=0$  și că, dacă este valabilă pentru  $t-1$ , atunci este valabilă și pentru  $t$ .